

Исследование качества конвертации синтаксической разметки корпуса СинТагРус в формат Универсальных зависимостей

Тимченко Д.¹, Мовсисян А.²

¹ Московский физико-технический институт (национальный исследовательский университет), 141701, Московская обл., г. Долгопрудный, Институтский пер., д. 9.

² Институт проблем передачи информации им. А. А. Харкевича РАН, 127051, г. Москва, Б. Каретный пер., д. 19, стр. 1
danitim4@gmail.com

Аннотация В данной работе исследуется качество конвертации синтаксической разметки глубоко аннотированного корпуса СинТагРус в формат Универсальных зависимостей. В силу различий между оригинальной и сконвертированной версиями корпуса, включая безусловные обороты, пунктуацию и эллипсис, прямое сравнение этих версий затруднено. Для устранения упомянутых различий были разработаны специальные правила и методы, включая использование маскированной языковой модели для обработки предложений с эллипсисом, не требующие явного восстановления элидированных словоформ, что позволило выравнять 99.43 % предложений. Качество конвертации исследовалось с помощью сравнения одной и той же модели автоматической синтаксической разметки, обученной независимо на обеих версиях корпуса. Полученные результаты показали, что прежде всего необходимо обеспечить согласованность в разметке между различными частями сконвертированного корпуса. Кроме того, были предложены рекомендации по улучшению правил конвертации, основанные на обнаруженных группах характерных ошибок.

Ключевые слова: Автоматическая синтаксическая разметка, конвертация, корпус текстов.

1 Введение

В современной компьютерной лингвистике активно используются аннотированные корпуса текстов, в том числе и корпуса, снабженные синтаксической разметкой, где каждому предложению ставится в соответствие его синтаксическая структура в виде дерева зависимостей. Узлами этого дерева являются слова, а направленными ребрами — синтаксические отношения между словами. Способ построения такого дерева и перечень используемых для этого синтаксических отношений различается не только между языками, но и между разными корпусами одного языка.

В попытке сблизить синтаксическое описание между языками был создан проект Универсальных зависимостей (Universal Dependencies, UD) [8]. Для большинства языков, в том числе и русского, существующие в рамках этого проекта корпуса были получены полуавтоматически с помощью конвертации уже существующих корпусов. Как правило, способы построения синтаксических деревьев сильно различаются между оригинальным корпусом и его версией в формате UD. Это требует составления сложных правил конвертации и ручной проверки, однако устранить ошибки конвертации удастся далеко не всегда, что затрудняет использование корпуса как для теоретических исследований, так и при его использовании как источника данных для решения прикладных задач.

Целью данной работы является исследование качества конвертации синтаксической разметки глубоко аннотированного корпуса русского языка СинТагРус [11] в формат UD. Для этого одна и та же модель автоматической синтаксической разметки была обучена на обеих версиях корпуса и были исследованы ошибки, встречающиеся только в версии после конвертации. Однако прямое сравнение корпусов невозможно из-за различий в обработке многословных оборотов, пунктуации и эллипсиса. Для устранения первых двух расхождений нами использовались специальные правила. Для выравнивания предложений с эллипсисом был предложен подход, использующий маскированную языковую модель и позволяющий подавать элидированную словоформу на вход модели без восстановления эллипсиса в явном виде. Выравнивая по словоформам большинство предложений двух версий корпуса, были проанализированы ошибки конвертации и сформулированы рекомендации по улучшению качества конвертации.

2 Обзор связанных работ

Описание первой версии конвертера СинТагРус в формат UD приведено в работе [5]. Это правилковый конвертер; результат его работы был проверен вручную, и первая версия сконвертированного корпуса появилась в UD версии 1.3 в мае 2016 года. В июле 2018 года русскоязычных корпусов в составе UD было уже 4. Авторы работы [4] количественно оценили согласованность разметки между этими четырьмя корпусами, используя модифицированную версию подхода, описанного в работе [7], где предлагалось обучить одну и ту же модель автоматической синтаксической разметки на двух различных корпусах испанского языка в формате UD и сравнить качество разметки между корпусами. В качестве количественных оценок точности в работах [4] и [7] были использованы оценка точности выбора правильного слова-хозяина без учета типа связи (Unlabeled Attachment Score, UAS) и с учетом типа связи (Labeled Attachment Score, LAS). При этом качество конвертации корпусов не оценивалось.

В работе [9] оценивается качество конвертации для корпусов английского языка. Для этого были рассмотрены разные подходы к конвертации и проведено сравнение результатов конвертации с небольшим фрагментом, скон-

вертированным вручную. Авторы показали, что качество конвертации улучшается, если использовать в правилах конвертации дополнительные типы разметки, содержащиеся в корпусе, включая именованные сущности и кореферентные цепочки. Однако предложенный авторами подход к сравнению качества конвертации требует трудозатратной полностью ручной конвертации разметки экспертами-лингвистами. Кроме того, предложенные авторами подходы к конвертации, в отличие от конвертации СинТагРус, касаются только синтаксических отношений и не меняют число слов в предложении, что упрощает сравнение.

Похожий на проведенный в данной работе эксперимент проводился в работе [10]. Целью этой работы являлась конвертация корпуса текстов на турецком языке в формат UD. Помимо этого, качество конвертации было оценено с помощью сравнения оценок качества разметки UAS и LAS одной и той же модели автоматической синтаксической разметки на корпусах до и после конвертации. При этом никакого детального анализа ошибок конвертации в работе проведено не было.

3 Описание данных

Исходными данными можно считать два синтаксически аннотированных корпуса: оригинальный СинТагРус и сконвертированный в формат UD. Последний далее будет называться СинТагРус-UD. В этом разделе описываются особенности двух корпусов и проведенная нами предобработка данных.

3.1 Ключевые различия между корпусами

Есть три отличия в синтаксической разметке корпусов СинТагРус и СинТагРус-UD, являющиеся основными причинами расхождений в длинах предложений. Во-первых, это пунктуация. В СинТагРусе знаки пунктуации не имеют никакого морфосинтаксического описания, тогда как в СинТагРусе-UD они являются полноценными узлами синтаксической структуры. Они не могут иметь зависимых узлов и связываются только специальным отношением *punct* со словами, не являющимися знаками пунктуации.

Во-вторых, это т. н. безусловные обороты, такие как *а именно*, *во что бы то ни стало* и др. В СинТагРусе такие обороты зачастую соответствуют одному узлу синтаксической структуры. В СинТагРусе-UD принято решение исключать ситуации, когда знак пробела содержится в узле, за редким исключением (например, для чисел типа *20 000*).

В-третьих, это эллипсис, который в СинТагРусе восстанавливается. Например, в синтаксическую структуру предложения *Это казалось важным, а затруднительность — нелепой.* в явном виде добавляется узел [казаться]. Он не имеет текстового представления, но к нему и от него проводятся все необходимые синтаксические связи, как и в случае обычных слов. В СинТагРусе-UD ситуация двоякая. С одной стороны, эллипсис в нем не

восстанавливается, а его индикатором в случае, когда опущенное слово является вершиной глагольной группы, является специальное синтаксическое отношения *orphan*, проводимое между его зависимыми. С другой стороны, в UD помимо (базовой) синтаксической структуры есть т. н. расширенная синтаксическая структура, которая не обязательно является деревом. Однако для корпуса СинТагРус-UD требование древовидности расширенной структуры соблюдается, а отличие от базовой состоит в восстановлении эллипсиса аналогично СинТагРусу.

3.2 Модификации корпусов

Для того, чтобы была возможность прямого сравнения соответствующих предложений двух корпусов, эти предложения были выравнены. Основные модификации были сделаны в отношении СинТагРуса, так как он постоянно улучшается и не имеет зафиксированных промежуточных версий, в отличие от корпуса СинТагРус-UD. При этом для сравнения использовалась та же версия СинТагРуса, которая использовалась при конвертации. В действительности эта версия состоит из двух: первая часть была взята в 2015 году, а вторая часть состоит из новых текстов, которые были размечены с 2015 по 2021 год.

Модификация СинТагРуса состояла в следующем:

- Корпус был сконвертирован из формата XML в используемый в UD формат CoNLL-U.
- Все безусловные обороты были разделены на отдельные узлы. Это стало возможным благодаря составленным лингвистами правилам, которые были написаны для улучшения поиска по СинТагРусу как составной части Национального корпуса русского языка³.
- Все знаки препинания были добавлены в базовую синтаксическую структуру и получили тип отношения *punct*, используемый в UD. Помимо этого, так как в формате разметки UD знаки препинания являются полноценными узлами, номер их слова-хозяина копировался из соответствующего предложения в корпусе UD. При наличии между соответствующими предложениями других расхождений в пунктуации, СинТагРус-UD считался эталоном и пунктуация в СинТагРусе приводилась к соответствующему виду.

Единственная модификация СинТагРус-UD обусловлена отсутствием правил, позволяющих исключить из предложений с эллипсисом в СинТагРусе узлы, соответствующие элидированным словам. Чтобы число узлов совпадало и в этом случае, информация об эллипсисе, содержащаяся в расширенной структуре СинТагРус-UD, была перенесена в базовую синтаксическую структуру.

После всех модификаций оба корпуса были выравнены по предложениям по критерию полного совпадения словоформ (включая элидированные), а

³ <https://ruscorpora.ru/search/syntax>

затем синтаксическая структура предложения СинТагРуса, включающая в себя как слова, так и пунктуацию, была восстановлена по соответствующему предложению из корпуса СинТагРус-UD. Таким образом, было выравнено 99.43 % (86.8 тысяч) предложений относительно общего числа предложений в корпусе СинТагРус-UD. Статистика по выравненным корпусам, а также современной версии СинТагРуса, представлена в Таблице 1.

Таблица 1. Статистика по корпусам СинТагРус, СинТагРус-UD и современной версии СинТагРуса. Число связей и проективность считаются без учёта пунктуации. Число типов связей считается без учёта нескольких ошибок в СинТагРусе, обусловленных опечатками.

Название корпуса	Современный СинТагРус	СинТагРус	СинТагРус-UD
Число предложений:	110 358	88 401	87 336
Из них эллиптические:	2 957	1 887	1 763
Число слов:	1 565 613	1 253 579	1 234 962
Из них элидированные:	3 924	2 482	2 196
Число связей:	1 565 613	1 253 579	1 237 155
Из них проективные:	1 534 466	1 228 623	1 219 056
Из них непроективные:	31 147	24 956	18 099
Типов связей:	69	69	46

4 Эксперименты и результаты

В данном разделе описываются количественные и качественные эксперименты, которые были проведены на двух выравненных корпусах, а также полученные результаты.

4.1 Описание экспериментов

В основе экспериментов лежит модель автоматической синтаксической разметки, которая использовалась нами для обучения на двух выравненных корпусах независимо. В качестве самой модели был выбран DiaParser [1]. Эта модель является модификацией известной модели из работы [3]. В частности, в ней вместо рекуррентной нейронной сети в качестве кодера используется предобученная большая языковая модель BERT [2]. Это, в частности, позволяет добиться достаточно высокого качества автоматической синтаксической разметки, не используя никаких дополнительных признаков, включая морфологическую разметку, что дало возможность не восстанавливать морфологическую разметку при выравнивании корпусов (ее, например, нет у элидированных слов в СинТагРусе-UD).

Для наших экспериментов было сделано две модификации модели. Во-первых, в качестве предобученной языковой модели использовалась модель RuBERT [6].

Во-вторых, была сделана модификация, позволяющая обрабатывать предложения с эллипсисом. В задаче построения модели автоматической синтаксической разметки предложения с эллипсисом пришлось бы отбросить или разрабатывать для них отдельный модуль, поскольку на этапе предсказания такие предложения невозможно разметить: расположение элидированной словоформы в неразмеченном предложении неизвестно. Однако в задаче оценки качества конвертации разметка предложений тестовой выборки дана. В связи с этим, во время обучения модели все элидированные словоформы, которые подавались на вход BERT’a, заменялись на маскировочный токен, который использовался при обучении самой модели RuBERT. Таким образом, можно сказать, что модель косвенно восстанавливала эллипсис, решая задачу маскированной языковой модели, на которой она предобучалась.

В качестве метрик использовались UAS, LAS, UCM (процент предложений, в которых для каждого слова правильно размечено слово-хозяин без учета типа связи) и LCM (процент предложений, в которых для каждого слова правильно размечены и слово-хозяин с учетом типа связи). Эти метрики отражают качество разметки, однако сравнение этих метрик между корпусами до и после конвертации позволяет косвенно сделать выводы о качестве конвертации.

4.2 Результаты экспериментов

Значения метрик UAS, LAS, UCM и LCM на тестовых выборках представлены в Таблице 2. Для того, чтобы оценить, влияние неполного выравнивания на качество модели автоматической синтаксической разметки, была обучена третья модель на всём корпусе СинТагРус-UD. В Таблице 3 отдельно приведены те же метрики для предложений с эллипсисом.

Таблица 2. Значения метрик UAS, LAS, UCM и LCM на тестовых выборках выравненных корпусов до и после конвертации и полного корпуса СинТагРус-UD. Полужирным выделены лучшие результаты для каждой метрики.

Название корпуса	UAS, %	LAS, %	UCM, %	LCM, %
СинТагРус	96.26	92.26	69.18	44.81
СинТагРус-UD	95.87	92.96	69.24	52.27
СинТагРус-UD (полный)	95.86	92.99	68.67	51.85

Таблица 3. Значения метрик UAS, LAS, UCM и LCM на тестовых выборках выравненных корпусов до и после конвертации для предложений с эллипсисом. Полужирным выделены лучшие результаты для каждой метрики.

Название корпуса	UAS, %	LAS, %	UCM, %	LCM, %
СинТагРус	88.93	84.78	23.53	8.82
СинТагРус-UD	87.45	84.07	20.00	13.53

5 Анализ

В данном разделе анализируются результаты экспериментов и проводится качественное исследование точности конвертации на примере характерных групп ошибок.

5.1 Общая точность разметки

Из Таблицы 2 видно, что небольшое сокращение объема корпуса СинТагРус-UD из-за выравнивания не оказало сильного влияния на качество разметки, и, более того, точность на уровне предложений ниже для полного корпуса. Это может свидетельствовать о том, что среди невыравненных предложений могли быть как ошибки конвертации, так и ошибки в разметке самого СинТагРуса.

Точность выбора типа связи для корпуса СинТагРус на уровне слов оказывается меньше, чем в СинТагРусе-UD, что может объясняться присутствием в этом корпусе группы комплетивных и несобственно-комплетивных связей: порядок заполнения валентностей часто определяется исключительно моделью управления, приведенной в специальном комбинаторном словаре и недоступной модели.

5.2 Характерные ошибки конвертации

Среди возможных причин ошибки модели автоматической синтаксической разметки можно выделить три основные группы:

1. Ошибки, вызванные ошибками разметки в СинТагРусе.
2. Ошибки, вызванные ошибками конвертации.
3. Ошибки самой модели.

Наибольший интерес для нас представляют ошибки типа 2. Чтобы выделить их из общего числа ошибок, рассмотрим те случаи, где моделью, обученной на СинТагРусе (далее модель СинТагРуса), был дан правильный ответ, в то время как модель, обученная на СинТагРусе-UD (далее модель UD), допустила ошибку. Таких случаев оказалось 4150 из 6054 ошибок в тестовой выборке СинТагРусе-UD. Здесь и далее под ответом модели мы подразумеваем тип связи для некоторого слова-слуги, поскольку каждое слово зависит только от одного другого слова.

Для выделения конкретных групп ошибок конвертации была составлена таблица следующей структуры. Зафиксируем конкретный тип синтаксического отношения в СинТагРусе и рассмотрим слова, зависящие по этому отношению. Если число ошибок модели UD для соответствующих слов тестовой выборки СинТагРус-UD высокое, то можно предполагать, что в этих случаях наблюдаются ошибки конвертации, так как моделью СинТагРус-UD этих ошибок в соответствующих словах допущено не было. Таким образом были сформированы группы ошибок, где группой считалась уникальная пара (предсказание модели UD, тип связи в разметке СинТагРус), и для каждой пары были определены число и процент ошибок относительно всех предсказаний для данной уникальной пары, а также найдены наиболее частотные правильные типы связи в UD для данной пары.

Результаты данного эксперимента представлены в Таблице 4. Пороговыми значениями для данных групп было выбрано число не менее 10 и частота не менее 50 %. Данная таблица оказалась недостаточно информативной, поэтому была составлена таблица с похожей конфигурацией, за исключением того, что в ней группой считалась уникальная пара (тип связи в разметке UD, тип связи в разметке СинТагРус). Результаты такой группировки, отсортированные по частотности, представлены в Таблице 5. В данной таблице представлены 10 наиболее частотных групп ошибок, из них рассматривались первые 9, поскольку доля остальных групп ошибок значительно ниже 50 %.

Таблица 4. Наиболее частотные ошибки модели UD, сгруппированные по парам (предсказание модели UD, тип связи в разметке СинТагРус). В таблице также приведено число ошибок в модели UD для данного типа связи внутри группы, частотность ошибки для этой связи по отношению к общему числу связей внутри группы и наиболее частотные правильные типы связей СинТагРус-UD внутри группы (UD golds).


	UD pred	СинТагРус gold	Число	Частота, %	UD golds
1	root	предик	15	93.75	nsubj, csubj, root
2	nsubj	1-компл	19	86.36	obj, obl, nsubj
3	obl:tmod	обст	18	72.00	obl, obl:tmod, advmod
4	xcomp	присвяз	22	62.86	obl, xcomp

Дальнейший анализ Таблицы 5 показал, что большинство найденных нами ошибок конвертации обусловлены рассогласованием разметки. Вероятно, процесс конвертации между первой частью корпуса, взятой в 2015 году, и второй частью, взятой в 2021, различался. Покажем это на примере некоторых групп ошибок, рассматривая в них наиболее частотные предсказаниям из колонки UD preds. Все приведенные далее примеры наблюдаются только в части корпуса, сконвертированной в 2015 году.


Таблица 5. Наиболее частотные ошибки модели UD, сгруппированные по парам (тип связи в разметке СинТагРус-UD, тип связи в разметке СинТагРус). В таблице также приведено число ошибок в модели UD для данного типа связи внутри группы, частотность ошибки для этой связи по отношению к общему числу связей внутри группы и наиболее частотные предсказания модели UD внутри группы (UD preds), включая правильное.

	UD gold	СинТагРус gold	Число	Частота, %	UD preds
1	case	сравнит	66	100.00	mark
2	obl:agent	агент	38	100.00	obl
3	mark	огранич	24	96.00	cc, mark, advmod
4	iobj	обст	25	92.59	obl, iobj, nsubj
5	acl	1-компл	45	91.84	obl, acl, nmod
6	xcomp	присвяз	80	86.02	obl, xcomp, advmod
7	obl:tmod	длительн	25	83.33	obl, obl:tmod, nummod:gov
8	obl:tmod	обст	34	82.93	obl, obl:tmod, parataxis
9	appos	примыкат	21	77.78	parataxis, appos
10	det	1-компл	22	38.60	det, nmod, obj


Ошибка присваивания *obl* вместо *xcomp*. Рассмотрим тип связи *присвяз* в СинТагРусе. В конструкциях с составным именным сказуемым, для всех глаголов-связок за исключением *быть* на именную часть сказуемого должна идти связь *xcomp*, что не всегда выполняется для предложений после конвертации. Пример (1) иллюстрирует неправильно присвоенную связь *obl* в составном именном сказуемом *стала жертвой*.



Ошибка присваивания *mark* вместо *case*. Рассмотрим тип связи *сравнит* в СинТагРусе. В неклаузальной сравнительной конструкции с союзами *как*, *чем*, *будто*, *словно* и т. п. союз связывается со словом, обозначающим стандарт сравнения, с помощью отношения *case*. Таким образом, проведение к союзу *как* связи *mark* подразумевает, что он является подчинительным союзом, а не сравнительным, и это является ошибкой конвертации. Пример (2) иллюстрирует неправильно присвоенную связь *mark* в сравнительной конструкции *как должно*.



Группа ошибок неуточнённого модификатора *obl*. Данная группа ошибок включает в себя случаи, когда при конвертации было присвоено отношение *obl* в тех случаях, где правильным было бы присвоить его существующее уточнение, например *obl:agent* и *obl:tmod*. Пример (3) иллюстрирует ситуацию, когда обстоятельство времени некорректно присоединяется по отношению *obl*.



Ср. с примером (4) из части корпуса, сконвертированной в 2021 году:



5.3 Точность разметки элидированных словоформ

В Таблице 6 приведены метрики UAS и LAS для элидированных, зависящих от элидированных и всех остальных узлов среди предложений с эллипсисом. Такие низкие значения метрик для элидированных словоформ мы связываем с тем, что по умолчанию в модели DiaParser веса предобученной языковой модели были заморожены. Несмотря на то, что при обучении для элидированных словоформ фактически решается задача маскированного языкового моделирования, она не тождественна задаче, решаемой в процессе предобучения, поскольку опущенные словоформы могут состоять из более чем одного токена, а мы для каждой словоформы добавляем только один. Разморозка весов могла бы помочь, но это потребовало бы больших вычислительных ресурсов на подбор гиперпараметров. Однако это повлияло на эффективность нашего подхода незначительно, поскольку качество разметки типов связей остальных слов в предложениях с эллипсисом (которых на порядок больше элидированных словоформ) неотличимы от аналогичных показателей для предложений без эллипсиса, и позволило увеличить представительность сравниваемого материала.

Таблица 6. Оценки точности разметки типов связей для различных типов узлов среди предложений с эллипсисом.

Название корпуса	Слова					
	элидированные		зависимые от элидированных		остальные	
	UAS, %	LAS, %	UAS, %	LAS, %	UAS, %	LAS, %
СинТагРус	43.2	36.41	58.84	53.64	95.72	92.46
СинТагРус-UD	39.81	32.52	39.29	34.72	95.46	93.09

6 Заключение

В данной работе был проведен анализ точности конвертации корпуса СинТагРус в формат Универсальных зависимостей. Выравнивание версий корпуса до и после конвертации за счет обработки безусловных оборотов и пунктуации, а также маскирования элидированных словоформ при обучении модели автоматической синтаксической разметки, позволило провести прямое сравнение двух версий корпуса. Основные результаты экспериментов показали, что конвертация корпуса в формат UD не лишена недостатков. Нами было обнаружено рассогласование разметки между частями корпуса, сконвертированными в разное время. Исправление этих недостатков позволит улучшить качество корпуса в формате UD и поможет не только исследователям, использующим корпус для теоретических и прикладных исследований, но и поможет исследовать более тонкие ошибки конвертации в будущем.

В дальнейшем представляется целесообразным углубить исследование, проведенное в данной работе. Стоит рассмотреть более детально не только конвертацию синтаксиса, но и морфологии (в многозадачном режиме обучения). Также предполагается добиться полноценного выравнивания, в частности, за счет анализа композитных конструкций типа *экс-президент*, которые в СинТагРусе размечены как два узла. Отдельного внимания заслуживает исследование способов улучшения качества разметки эллипсиса. Это может быть как разморозка слоев предобученной языковой модели, так и, например, явное восстановление эллипсиса по информации, содержащейся в СинТагРусе, или определение числа маскировочных токенов для каждой элидированной словоформы. Также полезно будет попробовать выравнивать корпус в формате UD и современную версию СинТагРуса, что не только поможет увеличить общее качество разметки СинТагРуса за счет исправленных в современной версии ошибок, но и позволит оценить целесообразность повторной конвертации корпуса в формат Универсальных зависимостей.

Список литературы

- [1] Giuseppe Attardi, Daniele Sartiano и Maria Simi. «Biaffine Dependency and Semantic Graph Parsing for Enhanced Universal Dependencies». В: *Proceedings of the 17th International Conference on Parsing Technologies and the IWPT 2021 Shared Task on Parsing into Enhanced Universal Dependencies (IWPT 2021)*. Под ред. Stephan Oepen и др. Online: Association for Computational Linguistics, авг. 2021, с. 184–188. DOI: 10.18653/v1/2021.iwpt-1.19. URL: <https://aclanthology.org/2021.iwpt-1.19>.
- [2] Jacob Devlin и др. «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». В: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Под ред. Jill Burstein, Christy Doran и Thamar Solorio. Minneapolis,

- Minnesota: Association for Computational Linguistics, июнь 2019, с. 4171—4186. DOI: 10.18653/v1/N19-1423. URL: <https://aclanthology.org/N19-1423>.
- [3] Timothy Dozat и Christopher D. Manning. «Deep Biaffine Attention for Neural Dependency Parsing». В: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=Hk95PK91e>.
 - [4] Kira Droганова, Olga Lyashevskaya и Daniel Zeman. «Data conversion and consistency of monolingual corpora: Russian UD treebanks». В: *Proceedings of the 17th International Workshop on Treebanks and Linguistic Theories (TLT, SyntaxFest 2018)*. Linköping University Electronic Press. Нояб. 2018, с. 52—65.
 - [5] Kira Droганова и Daniel Zeman. *Conversion of SynTagRus (the Russian dependency treebank) to Universal Dependencies*. Тек. орч. Institute of Formal, Applied Linguistics (ÚFAL MFF UK), Faculty of Mathematics и Physics, Charles University, Czechia, 2016.
 - [6] Yuri Kuratov и Mikhail Arkhipov. «Adaptation of Deep Bidirectional Multilingual Transformers for Russian Language». В: *Computational Linguistics and Intellectual Technologies. Papers from the Annual International Conference "Dialogue"(2019)*. 2019, с. 333—339.
 - [7] Hector Martinez Alonso и Daniel Zeman. «Universal Dependencies for the AnCora treebanks ». В: *Procesamiento del Lenguaje Natural 57* (сент. 2016). URL: <https://inria.hal.science/hal-01426751>.
 - [8] Joakim Nivre и др. «Universal Dependencies v2: An Evergrowing Multilingual Treebank Collection». English. В: *Proceedings of the Twelfth Language Resources and Evaluation Conference*. Под ред. Nicoletta Calzolari и др. Marseille, France: European Language Resources Association, май 2020, с. 4034—4043. ISBN: 979-10-95546-34-4. URL: <https://aclanthology.org/2020.lrec-1.497>.
 - [9] Siyao Peng и Amir Zeldes. «All Roads Lead to UD: Converting Stanford and Penn Parses to English Universal Dependencies with Multilayer Annotations». В: *Proceedings of the Joint Workshop on Linguistic Annotation, Multiword Expressions and Constructions (LAW-MWE-CxG-2018)*. Под ред. Agata Savary и др. Santa Fe, New Mexico, USA: Association for Computational Linguistics, авг. 2018, с. 167—177. URL: <https://aclanthology.org/W18-4918>.
 - [10] Umut Sulubacak и др. «Universal Dependencies for Turkish». В: *Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: Technical Papers*. Под ред. Yuji Matsumoto и Rashmi Prasad. Osaka, Japan: The COLING 2016 Organizing Committee, дек. 2016, с. 3444—3454. URL: <https://aclanthology.org/C16-1325>.
 - [11] Е. С. Иншакова и др. «СинТагРус сегодня». В: *Труды Института русского языка им. В. В. Виноградова 21* (2019), с. 14—41.