
Исследование качества конвертации синтаксической разметки корпуса СинТагРус в формат Универсальных зависимостей


Даниил Тимченко, Андрей Мовсесян
ИТиС, 19.09.24



Описание темы исследования



Корпус — это большая коллекция текстов, которые могут быть аннотированы дополнительной информацией, например, **синтаксической разметкой**.




Характерный вид синтаксической разметки — **дерево зависимостей**, в котором узлы — это **слова**, а связи между ними — **синтаксические отношения**.

Описание темы исследования



СинТагРус — синтаксически аннотированный корпус текстов русского языка. Содержит более *110 тысяч* синтаксически размеченных предложений.


Универсальные зависимости (Universal Dependencies, UD) — проект по созданию синтаксически аннотированных корпусов, основная цель которого — создать **стандартизированную схему синтаксической аннотации**.





Ключевые **различия** оригинальной и сконвертированной версий СинТагРуса это:

- Отсутствие разметки пунктуации в СинТагРусе.
- Разбиение *безусловных оборотов* в СинТагРусе-UD.
- Явное восстановление *эллипсиса* в СинТагРусе.



Описание данных




После модификации обоих корпусов, было достигнуто их **выравнивание** по **86.8 тысячам** предложений (**99.43 %** сконвертированного корпуса).

Название корпуса	Современный СинТагРус	СинТагРус	СинТагРус-UD
Число предложений:	110 358	88 401	87 336
Из них эллиптические:	2 957	1 887	1 763
Число слов:	1 565 613	1 253 579	1 234 962
Из них элидированные:	3 924	2 482	2 196
Типов связей:	69	69	46




Главный элемент всех экспериментов — **две модели** одного и того же **парсера**¹, обученные на двух выравненных версиях корпуса.



¹<https://github.com/Unipisa/DiaParser>



Ключевая модификация оригинальной модели — использование **маскировочного токена** для представления элидированных словоформ.





Название корпуса	UAS, %	LAS, %	UCM, %	LCM, %
СинТагРус	96.26	92.26	69.18	44.81
СинТагРус-UD	95.87	92.96	69.24	52.27
СинТагРус-UD (полный)	95.86	92.99	68.67	51.85

$$\text{UAS} = \frac{\text{количество верных направлений зависимостей (слов-хозяинов)}}{\text{общее количество зависимостей}}$$

$$\text{UCM} = \frac{\text{количество предложений с полностью верной структурой}}{\text{общее количество предложений}}$$




Основа **качественного анализа** — детальное рассмотрение систематических случаев ошибки парсера, обученного на СинТагРусе-UD.

	UD gold	СинТагРус gold	Число	Частота, %	UD preds
1	case	сравнил	66	100.00	mark
2	obl:agent	агент	38	100.00	obl
3	mark	огранич	24	96.00	cc, mark, advmod
4	iobj	обст	25	92.59	obl, iobj, nsubj
5	acl	1-компл	45	91.84	obl, acl, nmod
6	xcomp	присвяз	80	86.02	obl, xcomp, advmod
7	obl:tmod	длительн	25	83.33	obl, obl:tmod, nummod:gov
8	obl:tmod	обст	34	82.93	obl, obl:tmod, parataxis
9	appos	примыкат	21	77.78	parataxis, appos
10	det	1-компл	22	38.60	det, nmod, obj



Пример ошибки присваивания синтаксической связи *obl* вместо *xcomp* при фиксированной связи СинТагРуса *присвяз*:



Результаты и анализ



Точность **конвертации эллипсиса** была оценена с помощью измерения отдельных количественных метрик UAS и LAS.

Название корпуса	Слова					
	элидированные		зависимые от элидированных		остальные	
	UAS, %	LAS, %	UAS, %	LAS, %	UAS, %	LAS, %
СинТагРус	43.2	36.41	58.84	53.64	95.72	92.46
СинТагРус-UD	39.81	32.52	39.29	34.72	95.46	93.09



Основные выводы:

- Предложен **способ выявления групп ошибок конвертации**, основанный на сравнении разметки для одних и тех же предложений из выравненных корпусов.
- Предложена **модификация** модели автоматической синтаксической разметки, **позволяющая обрабатывать предложения с эллипсисом**.
- Исследованы **рассогласования в разметке** сконвертированного корпуса.



Возможности для потенциальных улучшений:

- Версии корпуса до и после конвертации были выравнены **не полностью**.
- Модель не была способна полностью адаптироваться к задаче обработки элидированных словоформ из-за **замороженных весов** модели BERT.
- Были рассмотрены только ошибки рассогласования, и не рассматривалась **морфологическая разметка**.